

## **Caso Grupo 1 – Retail (Rossmann): ETL con AWS Glue + Workflow y Dashboards**

Dataset: store.csv + sample\_submission.csv

### **1. Contexto del negocio**

Una cadena retail con cientos de tiendas desea entender mejor su portafolio, la presión competitiva y el impacto de promociones. El objetivo es construir un pipeline de datos automatizado en AWS Glue que permita transformar archivos CSV en tablas analíticas Parquet y habilitar dashboards ejecutivos.

### **2. Objetivos de aprendizaje**

- Diseñar un pipeline ETL en AWS Glue de extremo a extremo.
- Organizar datos en Amazon S3 (raw y curated).
- Crear Glue Data Catalog con Crawlers.
- Construir Jobs ETL en Glue (PySpark).
- Implementar un Workflow de Glue con Triggers.
- Crear dashboards analíticos y responder preguntas de negocio.

### **3. Archivos CSV entregados**

- store.csv – información estructural de las tiendas.
- sample\_submission.csv – ventas pronosticadas (forecast).

### **4. Arquitectura propuesta**

- 1) S3 Raw: carga de archivos CSV.
- 2) Glue Crawler RAW: inferencia de esquemas.
- 3) Glue Jobs ETL: limpieza y transformación a Parquet.
- 4) S3 Curated: almacenamiento analítico.
- 5) Athena: consultas SQL.
- 6) Dashboards: QuickSight / Power BI.

### **5. Organización en S3**

Bucket sugerido: s3://uh-retail-grupo1/

- raw/store/
- raw/sample\_submission/
- curated/dim\_store/
- curated/fact\_sales\_forecast/

## 6. ETL con AWS Glue (Jobs)

- Transformaciones mínimas requeridas:
  - Estandarizar nombres de columnas (minúsculas, snake\_case).
  - Conversión correcta de tipos de datos numéricos.
  - Tratamiento documentado de valores nulos.
  - Creación de columnas derivadas en dim\_store:
    - - competition\_open\_year\_month (YYYY-MM).
    - - promo2\_start\_year\_week (YYYY-WW).
    - - promo\_interval\_array (array).
  - Conversión de CSV a Parquet.
  - Escritura en S3 Curated y registro en Glue Catalog.

## 7. Modelo analítico sugerido

- Dimensiones:
  - dim\_store
- Hechos:
  - fact\_sales\_forecast

## 8. AWS Glue Workflow (OBLIGATORIO)

El Grupo 1 debe implementar un AWS Glue Workflow que automatice el pipeline completo. Se debe evidenciar gráficamente el workflow y demostrar al menos una ejecución exitosa.

### 8.1 Componentes del Workflow (nombres sugeridos)

- Workflow: wf\_retail\_grupo1
- Crawler RAW: crw\_retail\_grupo1\_raw
- Job 1: job\_raw\_to\_parquet\_store
- Job 2: job\_build\_dim\_store
- Job 3: job\_build\_fact\_sales\_forecast
- Crawler Curated: crw\_retail\_grupo1\_curated

### 8.2 Triggers requeridos

- Trigger A (ON\_DEMAND o SCHEDULED): inicia el workflow y ejecuta crw\_retail\_grupo1\_raw.
- Trigger B (CONDITIONAL): al finalizar el crawler RAW → ejecutar job\_raw\_to\_parquet\_store.
- Trigger C (CONDITIONAL): al finalizar job\_raw\_to\_parquet\_store → ejecutar job\_build\_dim\_store.
- Trigger D (CONDITIONAL): al finalizar job\_build\_dim\_store → ejecutar job\_build\_fact\_sales\_forecast.

- Trigger E (CONDITIONAL): al finalizar job\_build\_fact\_sales\_forecast → ejecutar crw\_retail\_grupo1\_curated.

### 8.3 Reglas del Workflow

- Los triggers B-E deben ser de tipo CONDITIONAL.
- El workflow debe detenerse si algún Job falla..
- Documentar errores encontrados y cómo se corrigieron.

## 9. Dashboards requeridos

### Dashboard 1 – Portafolio de tiendas

- Total de tiendas.
- Distribución por StoreType y Assortment.
- Distancia promedio a la competencia.
- % de tiendas con Promo2.

### Dashboard 2 – Competencia y promociones

- Tiendas por CompetitionOpenSinceYear.
- Comparación CompetitionDistance por StoreType.
- Distribución de Promo2 y PromoInterval.

### Dashboard 3 – Ventas pronosticadas

- Ventas pronosticadas totales.
- Distribución de Sales (p50, p75, p90).
- Top 50 registros por Sales.

## 10. Preguntas de negocio

1. ¿Cuántas tiendas hay por StoreType y Assortment?
2. ¿Qué porcentaje de tiendas participa en Promo2?
3. ¿Cuál es la distancia promedio a la competencia por StoreType?
4. ¿Qué tiendas enfrentan mayor presión competitiva?
5. ¿Cómo se distribuyen las aperturas de competencia por año?
6. ¿Qué patrones existen en Promo2?
7. ¿Cuál es el total de ventas pronosticadas?
8. ¿Cómo se distribuyen las ventas (outliers)?
9. ¿Qué decisiones de negocio se podrían tomar con este análisis?

## 11. Entregables

- Bucket S3 con raw y curated.
- Glue Data Catalog (RAW y CURATED).
- Workflow de Glue con triggers configurados.
- Captura de ejecución exitosa del workflow.
- Esquema en Redshift
- Dashboards funcionales.
- Documento de conclusiones.